

基于 StarVLA 的 CALVIN ABC→D 长程具身操控测评报告

待填写 待填写

代码仓库：待填写 模型权重：待填写

摘要：本报告面向“VLA/VA 模型长程操控基准测评”实训任务，基于 StarVLA 框架完成 CALVIN ABC→D split 上的 Action Policy Model 设计、训练、测评与失败分析。方案选择 VLA 路线中的 QwenPI 架构：以 Qwen3.5-4B 多模态模型作为视觉-语言骨干，以 Layer-wise Flow-Matching 动作头预测 7-DoF 连续动作块，并采用 LIBERO 预训练、CALVIN ABC→D 微调、Failure-Aware 后训练的三阶段流程。工程侧补齐了 CALVIN 数据准备、训练启动、评测日志、失败样本挖掘与加权动作损失等环节；分析侧围绕跨环境泛化、长程误差累积、动作精度和夹爪时序给出改进依据。

关键词：具身智能；Vision-Language-Action；StarVLA；CALVIN；长程操控；Failure-Aware Finetuning

1 任务概述

本次实训要求在两天内基于 StarVLA 框架完成一个可复现的 Action Policy Model，并在 CALVIN ABC→D 长程操控基准上评测。CALVIN 的核心难点不是单步抓取，而是模型需要在未见环境 D 中连续完成 5 个子任务；任意中间失败都会截断后续链条，因此它同时考察视觉泛化、语言条件理解、连续动作精度、闭环重规划和误差恢复能力。

交付目标包含五项：代码仓库、模型权重、CALVIN ABC→D 测评报告、技术路线与 Failure Pattern 文档、10 分钟答辩 PPT。本文覆盖其中的测评报告和技术文档，并给出复现实验所需的主要命令与代码路径。

2 技术路线选择

2.1 路线结论

本方案选择 VLA 路线而非纯 World Model 路线，具体配置为 Qwen3.5-4B + QwenPI + Layer-wise Flow-Matching action head。选择原因如下。

- 数据效率：Qwen 系列多模态模型已经具备语言-视觉对齐能力，在两天实训周期内，比从视频 DiT 世界模型中重新适配机器人动作更稳妥。
- 跨环境泛化：ABC→D 的主要挑战是视觉外观与初始状态变化。VLA 的语言条件和多层视觉 token 表征有利于把任务语义绑定到目标物体，而不是仅记忆训练场景轨迹。
- 长程规划：QwenPI 预测短动作块并在闭环中重规划，避免一次性输出过长轨迹导致误差不可修复；Flow-Matching 动作头比简单 MLP 更适合表达多模态连续动作分布。
- 计算成本：Qwen3.5-4B 在显存、训练时长和推理延迟上低于 CosmosPredict2/Wan 等视频生成式世界模型，适合夏令算力和时间约束。

World Model 路线的优势在于显式吸收视频预测模型中的物理与时序先验，理论上对遮挡、物体持久性和动态场景更有帮助。但在本任务中，WM4A 需要额外处理视频 DiT 特征抽取、VAE/T5/DiT 多模块加载和较高推理成本；如果没有充分调参时间，收益不一定能覆盖工程风险。

3 模型与训练方案

3.1 模型结构

模型输入包含静态相机图像、腕部相机图像和语言指令，输出为 7 维连续动作：

$$a_t = [\Delta x, \Delta y, \Delta z, \Delta r, \Delta p, \Delta y, g].$$

其中前三维为空间平移，后三维为姿态增量，最后一维为夹爪开合。

QwenPI 首先调用 Qwen3.5-4B 编码图像和指令，并保留多层 hidden states。Layer-wise Flow-Matching 动作头将多层 token 作为 cross-attention 条件，学习从噪声动作轨迹到真实动作块的速度场。推理时每次预测长度为 8 的动作 chunk，评测端每 5 步重新查询 policy server，使模型在子任务执行中持续闭环修正。




图 2: StarVLA 中不同动作头路线。本文采用 PI/Layer-wise FM，它比 OFT 更能表达连续动作不确定性，比 FAST 避免离散 token 量化误差。

3.2 三阶段训练

- LIBERO 预训练**：在 LIBERO 四个子集上训练动作头，并冻结 Qwen 主干，获得基础物体交互、夹爪控制和短程轨迹能力。




图 1: StarVLA 模块化框架。报告方案复用其统一数据、模型、训练与部署接口，仅在动作头、训练脚本和失败样本挖掘处做面向 CALVIN 的适配。

2. **CALVIN** 微调：使用 CALVIN ABC→D 的 LeRobot 格式训练集进行任务域适配，保持评测环境 D 不作为 D-only 训练集，避免数据泄漏。
3. **Failure-Aware** 后训练：评测脚本记录失败子任务、阶段、语言指令与 GIF 路径；数据加载器从 failure log 中挖掘高频失败指令，提高其采样比例，并在动作损失中强调平移、夹爪和后半段动作稳定性。

4 工程实现

3.3 关键超参数

表 1: 主要训练配置

项目	设置
Framework	QwenPI
Base VLM	Qwen3.5-4B
Action head	LayerwiseFM / Flow-Matching DiT
Action dim	7
Action horizon	8
Pretrain data	LIBERO all suites
Finetune data	CALVIN ABC→D LeRobot train set
Pretrain steps	80k, frozen Qwen backbone
Finetune steps	30k, warm-start from LIBERO checkpoint
Post-train steps	5k, failure-aware sampling
Optimizer	AdamW, cosine schedule

4.1 代码修改概览

本次工程实现围绕“可跑、可测、可分析、可复训”四个目标组织。

表 2: 主要工程模块

文件或目录	作用
pretrain_scripts/01_pretrain_pi_freeze_qwen_lebero.sh	LIBERO 预训练入口, 冻结 Qwen, 训练 LayerwiseFM 动作头。
finetunescripts/00_prepare_calvin_dataset.sh	检查 CALVIN LeRobot 数据结构并补齐 modality.json。
finetunescripts/01_finetune_pi_calvin.sh	CALVIN ABC→D 微调主脚本, 封装路径、checkpoint、超参和 DeepSpeed 启动。
finetunescripts/03_posttrain_failure_aware_calvin.sh	基于失败日志的短程后训练入口, 设置 failure-aware 采样与动作损失权重。
examples/calvin/eval_files/eval_calvin.py	CALVIN 多步评测脚本, 输出 Task 1-5 成功率、平均链长和失败日志。
starVLA/dataloader/gr00t_lerobot/datasets.py	从失败日志提取高频失败语言指令, 并降低容易样本采样比例。
starVLA/model/modules/action_model/LayerwiseFM_ActionHeader.py	支持动作维度权重和时间步权重, 针对夹爪时序与后段漂移加强监督。

4.2 复现命令

Listing 1: 训练与评测主流程

```
# 1. Check CALVIN LeRobot training data.
bash finetunescripts/00_prepare_calvin_dataset.sh

# 2. Optional smoke test.
bash finetunescripts/02_smoke_finetune_pi_calvin.sh

# 3. LIBERO pretraining, if no warm-start checkpoint exists.
bash pretrain_scripts/01_pretrain_pi_freeze_qwen_lebero.sh

# 4. CALVIN ABC-D finetuning.
PRETRAINED_CHECKPOINT=/path/to/libero_pretrain.pt \
bash finetunescripts/01_finetune_pi_calvin.sh

# 5. Start policy server in StarVLA environment.
bash examples/calvin/eval_files/run_policy_server.sh

# 6. Run CALVIN evaluation in Calvin environment.
bash examples/calvin/eval_files/eval_calvin.sh

# 7. Failure-aware post-training.
PRETRAINED_CHECKPOINT=/path/to/calvin_finetune.pt \
FAILURE_AWARE_LOG_PATH=/path/to/failure_log.jsonl \
bash finetunescripts/03_posttrain_failure_aware_calvin.sh
```

5 测评协议与指标

评测使用 CALVIN ABC→D split, 测试环境为未见过的 D。每条序列包含 5 个连续自然语言子任务; 若第 k 个子任务失败, 则该序列后续任务不再计入成功。设第 i 条序列成功完成的子任务数为 $r_i \in \{0, 1, 2, 3, 4, 5\}$, 共 N 条序列, 则:

$$SR_k = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(r_i \geq k), \quad ACL = \frac{1}{N} \sum_{i=1}^N r_i.$$

其中 SR_k 是 Task k 阶段成功率, ACL 是 Average Chain Length, 满分为 5.0。

6 实验结果

表 3 的第一行用于填写本次最终提交结果。当前 ‘tex’ 已将数值抽成宏, 正式提交前只需修改导言区的 \OursAvg 与 \OursTaskOne-\OursTaskFive。下方 StarVLA 公开结果仅作为 sanity-check 参考, 用于判断本次结果是否处在合理区间。

7 Failure Pattern 分析

CALVIN ABC→D 中的失败主要不是独立同分布的单任务失败, 而是链式任务中的状态偏移不断放大。评测脚本将每次失败记录为 JSONL, 包含 sequence_i、subtask_i、stage、subtask、lang_annotation、reason 与调试 GIF 路径。这些日志既用于人工分类, 也直接作为后训练采样信号。

8 后训练设计

Failure-Aware 后训练包含两条线。第一条线是采样重加权: 从 failure_log.jsonl 中统计失败语言指令, 选取 Top-K 高频指令作为 hard language set。数据加载时保留 hard samples, 并以 $1/w$ 的概率接受非 hard samples, 从而在不复制数据的情况下提高失败模式出现频率。

第二条线是动作损失重加权。原始 Flow-Matching 速度场损失为:

$$\mathcal{L}_{FM} = \mathbb{E} \left[\|v_{\theta}(x_t, t, c) - (a - \epsilon)\|_2^2 \right],$$

其中 c 为视觉-语言条件。本实现加入维度权重 w_d 与时间权重 w_t :

$$\mathcal{L}_{\text{weighted}} = \frac{\sum_{t,d} w_t w_d (v_{\theta,t,d} - (a_{t,d} - \epsilon_{t,d}))^2}{\frac{1}{TD} \sum_{t,d} w_t w_d}.$$

该形式保持 loss 数值尺度稳定, 同时让夹爪控制和 chunk 后半段动作对梯度贡献更大。

表 3: CALVIN ABC→D 结果。Task 1-5 为阶段成功率，Avg. Length 为平均任务链长度。

模型	Avg. Length	Task 1	Task 2	Task 3	Task 4	Task 5
本次提交：QwenPI + Qwen3.5-4B + Failure-Aware	待填	待填	待填	待填	待填	待填
StarVLA QwenPI, Qwen3-VL-4B-Instruct	3.472	87.7%	75.2%	67.4%	61.8%	55.1%
StarVLA QwenPI, Qwen2.5-VL-3B-Action	3.576	90.9%	79.5%	69.6%	62.2%	55.4%
StarVLA QwenGR00T, Qwen3-VL-4B-Action	3.757	91.1%	81.8%	74.1%	67.6%	61.1%
PI0.5 reference	3.885	92.5%	84.0%	76.6%	71.0%	64.4%

表 4: 典型失败模式、根因与改进方案

失败模式	现象	根因分析	已实施/建议改进
误差累积	前 1-2 个任务成功，但物体或机械臂末端残留偏差导致后续失败。	动作 chunk 后半段对已偏移状态鲁棒性不足，训练中后段动作监督权重偏低。	加入后段动作权重 1.25；推理端每 5 步重规划；保留失败 GIF 做阶段定位。
环境 D 泛化失败	模型能接近目标区域，但对新背景、光照或物体位置变化反应迟缓。	ABC 训练分布和 D 的视觉纹理/布局存在偏移；VLM 主干冻结时域适配能力有限。	使用 LIBERO 预训练增强通用操作先验；可进一步加入颜色抖动、crop、相机扰动和指令改写。
长程规划退化	模型执行了局部可行操作，但与完整 5 步任务链的目标顺序不一致。	训练样本多为短窗口监督，缺少对上一子任务完成状态的显式记忆。	记录失败发生 stage；高频失败 stage 进入后训练；可扩展为历史图像/已完成任务 token 条件。
动作精度不足	接触点偏离、推拉距离不够、旋钮/滑块未达到 oracle 阈值。	连续动作回归对小幅位姿误差敏感；姿态和平移维度尺度不一致。	动作维度加权：平移权重 1.0，旋转 0.7，夹爪 1.5；必要时按任务类别加入末端误差课程学习。
夹爪时序错误	过早闭合、过晚释放或抓取后松开。	夹爪是离散倾向强的连续维度，MSE 中容易被平移/旋转误差淹没。	提高 gripper loss 权重；在失败样本中优先采样 open/-close 高频任务；可加入夹爪二分类辅助损失。

9 消融计划

表 5: 建议消融实验

实验	验证问题
QwenPI baseline	仅 CALVIN 微调，作为主基线。
+ LIBERO pretrain	验证跨任务操作先验是否提升 Task 1/2。
+ failure-aware sampling	验证失败高频任务是否提升 Task 3-5。
+ weighted action loss	验证夹爪和后段动作稳定性是否提升平均链长。
QwenGR00T 对比	验证双系统动作头是否在长程链条上更稳。

为证明改进有效，建议最终答辩展示以下最小消融。

10 个人贡献说明

- 完成 StarVLA/CALVIN 训练与评测流程梳理，明确训练数据、评测数据和 policy server 的环境边界。
- 实现或整理 LIBERO 预训练、CALVIN 微调、Failure-Aware 后训练脚本，降低路径配置和复现实验成本。
- 在 CALVIN 评测中增加失败日志与 summary 输出，使 Task 1-5 成功率之外的失败根因可追踪。
- 在数据加载中接入 failure-aware instruction mining，并在 LayerwiseFM 动作头中支持维度/时间加权损失。
- 整理技术路线论证、失败模式分类、复现实验命令和最终答辩材料。

11 结论

本文给出了一套面向 CALVIN ABC→D 的 StarVLA VLA 路线实现：以 Qwen3.5-4B 提供视觉-语言先验，以 QwenPI/LayerwiseFM 进行连续动作块预测，并通过 LIBERO 预训练、CALVIN 微调和 Failure-Aware 后训练逐步提升长程执行稳定性。与 WM 路线相比，该方案在两天实训约束下更容易复现和迭代；与单次微调相比，失败日志闭环让后训练能够直接针对 Task 3-5 的链式退化问题。最终提交时，需要用完整 CALVIN 评测输出替换表 3 的宏，并上传对应 checkpoint 链接。

参考文献

- [1] StarVLA Team. *StarVLA: A Lego-like Code-base for Vision-Language-Action Model Developing*. arXiv:2604.05014, 2026.
- [2] Mees, O., Hermann, L., Rosete-Beas, E., and Burgard, W. CALVIN: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. *IEEE Robotics and Automation Letters*, 2022.
- [3] Qwen Team. Qwen-VL and Qwen multimodal model series. Technical report and model documentation, 2024–2026.
- [4] NVIDIA. Cosmos Predict2 video world model documentation. 2026.